

Jonathan Wrede

Website: jonathanwrede.de
E-Mail : kontakt@jonathanwrede.de
GitHub : github.com/Jwrede
LinkedIn : linkedin.com/in/jonathan-wrede
Mobil : +49 151 - 29499386

AI Platform / ML Infrastructure Engineer für Kubernetes-ML-Systeme, Inferenz-Readiness, Observability und Datenplattformen.

Produktions-Workflows für 100.000+ IoT-Geräte; OSS in inference-readiness-kit, llmprobe, llm-d, OpenTelemetry und Feast.

BERUFSERFAHRUNG

- Vilisto** Hamburg
Machine Learning Engineer Jan. 2025 - Heute
 - Batterie-Gesundheit & Laufzeitvorhersage:** Kapazitäts- und Laufzeitvorhersage-Algorithmen mit Konfidenzintervallen für 100.000+ IoT-Thermostate (~400 Kunden) entwickelt; Batteriewechselkosten um EUR 50-100K im ersten Jahr gesenkt. Pipeline mit **Dagster** und **MLflow**.
 - Unternehmensdatenplattform (ELT):** Analytics-Warehouse aufgebaut: 95 **dbt**-Modelle, 5 Datenquellen mit PII-sicherer Aufnahme, automatisierte Tests/Lineage via **Dagster**, stufenweise Rollouts mit ArgoCD.
 - Flottenmonitoring:** **Grafana**-Dashboards und **Python**-Alerting-Service für 100.000+ Geräte, wodurch tagelanges manuelles Prüfen durch automatische Erkennung von Offline-Thermostaten und Gateway-Ausfällen ersetzt wurde.
 - Plattform & Tools:** Betrieb und Monitoring von Daten-/ML-Services auf **Kubernetes (Helm, Probes, Logs/Metriken)**; Labor-**FastAPI**-Dashboard für Batterietests mit automatischer Alarmierung.
- Saracus** Münster
Data Platform Consultant Jan. 2023 - Dez. 2024
 - Cloud-Datenplattformen:** Data Warehouses für 5 Unternehmenskunden in Versicherung, E-Commerce und Energie auf **Snowflake (AWS)**, **Google BigQuery** und **Azure Synapse** entworfen und deployed; automatisierte **Python**-ETL-Pipelines für Millionen von Datensätzen.
 - Anwendungsentwicklung:** Mehrere **Streamlit**-Apps mit OAuth-SSO, Snowflake-Integration und individuellen Visualisierungen; deployed via **Azure Container Apps**.
 - Data Governance:** **Master-Data-Management**-Lösung mit **Ataccama** + **Azure** implementiert; Glossarpflege mit **Azure Functions** und Python automatisiert.
- Vilisto** Hamburg
Werkstudent - Data Scientist Sep. 2021 - Okt. 2022
 - ML & Data Engineering:** Präsenzerkennungsmodelle mit **Python/scikit-learn** für tausende IoT-Thermostate erweitert; Schemata und Pipelines in **PostgreSQL/TimescaleDB** mit **SQL** und **pandas** aufgebaut.
 - Softwareentwicklung:** Beiträge zu Backend (**Python, Docker**) und Frontend (**TypeScript, Vue.js**); **PyQt**-Labeling-Tool entwickelt und interne Programmier-Workshops geleitet.
- TU Dortmund** Dortmund
Tutor - Datenstrukturen & Algorithmen Feb. 2021 - Okt. 2021

BILDUNG

- Universität Münster** Münster
Master Informatik Schwerpunkt KI / ML / Statistik Okt. 2023 - Okt. 2026
Thesis: Memory profiling and deployability of privacy-preserving transformer inference systems
- TU Dortmund** Dortmund
Bachelor Informatik mit Nebenfach Statistik Okt. 2019 - Apr. 2023
Thesis: Phase transitions in sparse principal component analysis

OPEN SOURCE & PROJEKTE

- inference-readiness-kit / llmprobe:** LLM-Inferenz-Readiness-Workflow: externe Probes, SLA-Gates mit Exit-Codes, Prometheus/vLLM-Korrelation, Concurrency-Sweeps, Grafana-Inspektion, Runbooks, Tests und CI. **Tech:** Python, Go, Prometheus, Grafana, vLLM
- AI-Plattform-OSS-PRs:** 7 OSS-Infrastruktur-PRs in llm-d, OpenTelemetry und Feast: Router-CI, OpenAI-Telemetrie, BigQuery-/DynamoDB-/Trino-Fixes.
- Transformer Inference Memory Benchmark:** M.Sc.-Thesis-Artefakt für Ressourcenprofiling und Deployability von Transformer-Inferenz; Operator-Level-RSS, Allocator-Verhalten und Laufzeit-Tradeoffs über FHE/MPC/FSS-Systeme gemessen; Peak-Speicher um 61-99% reduziert. **Tech:** Python, C++, Docker, PyTorch

TECHNISCHE KENNTNISSE

- Zielstack AI-Inferenz:** vLLM, SGLang, KServe, Gateway API/Envoy, llm-d, OpenTelemetry, Prometheus/Grafana, Readiness-Gates, KV-Cache, TTFT/TPOT-Benchmarking
- Infrastruktur & Cloud:** Kubernetes (Helm, ArgoCD), Terraform, Docker, AWS, Azure, GCP, Linux
- Daten & Backend:** Python, Go, SQL, dbt, PostgreSQL/TimescaleDB, Snowflake, BigQuery, FastAPI, Pandas/Polars
- Weitere Technologien:** TypeScript, Streamlit, Vue.js, scikit-learn, Ataccama, MinIO, Java